

# 하드웨어 특성에 최적화된 RocksDB WAL 튜닝

**RocksDB Study** 히로애락



윤치호 박규원 강민수 이우진

2026. 02. 11


# Contents

1. 실험1 이기종 프로세서 환경 (Heterogeneous Computing)
2. 실험 2 WAL Disk I/O 병목 개선
3. 향후 방향

# 실험1 이기종 프로세서 환경(Heterogeneous Computing)



## What is P-core & E-core ?



# Experimental configuration

| 항목      | 사양                                                  |
|---------|-----------------------------------------------------|
| OS      | WSL2 Ubuntu 24.04.03 LTS x86_64 (Kernel 6.14.0-37 ) |
| CPU     | Intel 155H                                          |
| Memory  | LPDDR5 16GB                                         |
| Drive   | 1TB NVME SSD Micron 2400 SSD 1TB pcie4 qlc          |
| RocksDB | 10.9.1                                              |

## CPU 사양

|                                |         |
|--------------------------------|---------|
| 코어 수 ⓘ                         | 16      |
| Performance-core의 수            | 6       |
| Efficient-core의 수              | 8       |
| 저전력 Efficient-cores 수          | 2       |
| 총 스레드 수 ⓘ                      | 22      |
| 최대 터보 주파수 ⓘ                    | 4.8 GHz |
| Performance-core 최대 터보 주파수 ⓘ   | 4.8 GHz |
| Efficient-core 최대 터보 주파수 ⓘ     | 3.8 GHz |
| 저전력 Efficient-core 최대 터보 주파수 ⓘ | 2.5 GHz |
| Performance-core 기본 주파수 ⓘ      | 1.4 GHz |
| Efficient-core 기본 주파수 ⓘ        | 900 MHz |
| 저전력 Efficient-core 기본 주파수 ⓘ    | 700 MHz |


# Hypotheses

Sync(on) & Async(off)의 병목에 따른 속도 차이가 있을 것이다

Sync(on)에서는 디스크 병목이 지배 → 코어 차이가 작다


성능 순위 예상:  $P > (\text{설정 없음}) > E$

## 결과 – Latency Comparison



# 결과 - 동기 처리 방식에서 프로세서별 성능 비교


**RocksDB Performance: Sync Mode (I/O Bound)**





# 결과 - 비동기 처리 방식에서 프로세서별 성능 비교

RocksDB Performance: Async Mode (CPU Bound)



# 결론

sync=true는 fsync 대기로 I/O bound가 되며 throughput/latency 상한이 디스크 지연에 의해 결정

sync=false는 CPU/스케줄링 영향이 커지고, 이기종 코어 특성(P/E) 차이가 드러나기 쉬움

호스트 OS인 윈도우에서 스케줄링을 통해 유휴 자원을 효과적으로 자율적으로 동원함

코어의 고정은 통제에는 유리하지만, OS의 동적 분산/유휴 자원 동원을 막아 성능을 제한할 수 있음

- 설정 없음 > P > e 코어 순으로 성능의 차이가 발생함


## 추가 실험

| 항목      | 사양                                             |
|---------|------------------------------------------------|
| OS      | Ubuntu 24.04.03 LTS x86_64 (Kernel 6.14.0-37 ) |
| CPU     | Intel 155H                                     |
| Memory  | LPDDR5 16GB                                    |
| Drive   | 1TB NVME SSD Micron 2400 SSD 1TB pcie4 qlc     |
| RocksDB | 10.9.1                                         |


# 추가 실험

## Performance Comparison (5 Runs Average)


Write Latency (micros/op)




Throughput (ops/sec)



Data Throughput (MB/s)






# 추가 실험



# 추가 실험

## Write Operation Metrics (5 Runs Average)



## Discussion

OS Scheduling 성능이 더 좋은 이유에 대한 심층 규명 필요

cgroup v2의 통합 계층 구조 환경에서 실험 환경 통제 필요

다양한 가상화 환경에서 실험 필요

# 실험 2 WAL Disk I/O 병목 개선

로그 전용 디스크 분리

`wal_bytes_per_sync`

Rate limiter



## Experiment - configuration


| 항목             | 사양                                                                                                       |
|----------------|----------------------------------------------------------------------------------------------------------|
| OS             | Ubuntu 24.04.03 LTS x86_64 (Kernel 6.14.0-37 )                                                           |
| CPU            | Intel 155H                                                                                               |
| Memory         | LPDDR5 16GB                                                                                              |
| Internal Drive | 1TB NVME SSD Micron 2400 SSD 1TB pcie4 qlc                                                               |
| External Drive | kioxia exceria plus g2 portable ssd 500GB<br>Max seq read 1050 MB/s write 1000MB/s connected via USB 3.2 |
| RocksDB        | 10.9.1                                                                                                   |

# Experiment – 성능 비교표


RocksDB 모든 시나리오 통합 성능 비교표

| 그룹        | 시나리오 이름                 | SST 위치 | WAL 위치 | 적용 옵션      | Avg OPS | P99.9 (us) | Stall% | WAF  |
|-----------|-------------------------|--------|--------|------------|---------|------------|--------|------|
| 기준점       | 0_Base_None             | NVMe   | NVMe   | 기본         | 414,694 | 2630.36    | 32.60% | 2.70 |
|           | Ref_AllExternal         | 외장SSD  | 외장SSD  | 기본         | 217,216 | 1803.32    | 58.76% | 2.12 |
| 아키텍처 A    | 1_Opt1_Split            | 외장SSD  | NVMe   | Split      | 256,142 | 2700.19    | 59.76% | 2.40 |
| (로그만 고속)  | 2_Combo_12_Split_Sync   | 외장SSD  | NVMe   | Split+Sync | 264,512 | 2194.75    | 46.34% | 2.46 |
|           | 2_Combo_13_Split_Rate   | 외장SSD  | NVMe   | Split+Rate | 259,237 | 2720.17    | 59.24% | 2.40 |
|           | 3_Full_123_Combined     | 외장SSD  | NVMe   | 전종합        | 284,862 | 2668.85    | 49.34% | 2.46 |
| 아키텍처 B    | Split_WAL_Ext_Only      | NVMe   | 외장SSD  | Split      | 362,375 | 2111.20    | 36.38% | 2.58 |
| (데이터 고속)  | Split_WAL_Ext_Sync      | NVMe   | 외장SSD  | Split+Sync | 250,890 | 1429.58    | 31.52% | 2.98 |
|           | Split_WAL_Ext_Rate      | NVMe   | 외장SSD  | Split+Rate | 230,510 | 2570.94    | 58.50% | 2.14 |
|           | Split_WAL_Ext_Sync_Rate | NVMe   | 외장SSD  | 전종합        | 235,289 | 1776.43    | 37.84% | 2.44 |
| S/W 최적화   | 1_Opt2_Sync             | NVMe   | NVMe   | Sync       | 302,125 | 2022.54    | 17.58% | 2.68 |
| (NVMe 기반) | 1_Opt3_Rate             | NVMe   | NVMe   | Rate       | 247,710 | 2554.92    | 57.06% | 2.20 |
|           | 2_Combo_23_Sync_Rate    | NVMe   | NVMe   | Sync+Rate  | 167,718 | 1273.03    | 3.00%  | 2.22 |


# Experiment – Average Ops Comparison



# Experiment – P99.9 Latency Comparison



# Experiment – P99.9 Latency Trade - off



## Result

1. 드라이브 분리는 시스템 처리량 개선에 제한적이고 안정성을 높인다.  
- 분리를 한다면 SST를 빠른 드라이브에 배치.
2. 안정성(Stall)의 핵심은 Sync 튜닝이다. (시스템콜 호출)
3. Rate Limiter는 단독으로 낮은 처리량, 높은 지연을 야기한다.

| 시나리오        | SST/WAL 위치  | Stall% | P99.9 (us) | 결과 분석                                                             |
|-------------|-------------|--------|------------|-------------------------------------------------------------------|
| 0_Base_None | NVMe / NVMe | 32.60% | 2630.36    | fsync 오버헤드로 인해 대기/스톨로 병목 발생                                       |
| 1_Opt2_Sync | NVMe / NVMe | 17.58% | 2022.54    | fsync 빈도 감소<br><b>Stall 대폭 완화</b><br>tail latency 개선<br>(최고의 안정화) |

| 주요 통찰(발견)        | 근거 데이터                                          | 의미(해석)                                                                 | 주요 통찰(발견)        | 근거 데이터                                          |
|------------------|-------------------------------------------------|------------------------------------------------------------------------|------------------|-------------------------------------------------|
| SST가 WAL보다 더 중요  | Split_WAL_Ext_Only OPS가 1_Opt1_Split보다 약 41% 높음 | Log(WAL)보다 Data(SST)/Compaction I/O를 빠른 디스크(NVMe)에 두는 것이 처리량 유지에 더 결정적 | SST가 WAL보다 더 중요  | Split_WAL_Ext_Only OPS가 1_Opt1_Split보다 약 41% 높음 |
| Sync 튜닝이 핵심 안정화책 | 1_Opt2_Sync에서 Stall% 17.58%로 급감                 | 고성능 디스크여도 fsync/동기화 호출을 “덜 자주” 만들어 I/O 오버헤드/대기를 줄이는 것이 안정성에 가장 효과적     | Sync 튜닝이 핵심 안정화책 | 1_Opt2_Sync에서 Stall% 17.58%로 급감                 |

**결론 ->** 병목은 WAL보다 SST(Compaction)에서 강하게 발생한다.  
고성능 드라이브에서는 **I/O 요청 횟수(Sync)를 줄이는 것이** 가장 효과적이다.

## Discussion – 목표에 따른 아키텍처 선택

| 목표              | 1순위 시나리오             | Avg OPS | P99.9  | Stall% | 선택 이유 및 권장 환경                            |
|-----------------|----------------------|---------|--------|--------|------------------------------------------|
| A. 최대 처리량       | 0_Base_None          | 414,694 | 2630us | 32.6%  | NVMe의 대역폭 극대화.<br>처리량 중요한<br>웹 캐시/분석 백엔드 |
| B. 최고의 안정성(QoS) | 2_Combo_23_Sync_Rate | 167,718 | 1273us | 3.00%  | 금융/거래 시스템<br>낮은 지연                       |
| C. 성능-안정성 밸런스   | 1_Opt2_Sync          | 302,125 | 2022us | 17.58% | 대부분의 범용 서비스                              |



## Discussion – 소프트웨어 튜닝 전략

| 워크로드 성격                    | 필수 옵션       | 옵션 2 (Sync)                        | 옵션 3 (Rate)               | 선택 아키텍처                                           |
|----------------------------|-------------|------------------------------------|---------------------------|---------------------------------------------------|
| 순수 처리량 (Bulk Write)        | 없음          | 비추천 (Stall이 32% 발생해도 총 OPS가 가장 높음) | 비추천                       | 0_Base_None (All NVMe)                            |
| 범용 서비스 (Latency-Sensitive) | Sync 필수     | 적용 (Stall 17.58%로 급감)              | 미적용                       | 1_Opt2_Sync (All NVMe)<br>Fast Data + Sync        |
| 금융/거래 (High QoS)           | Sync & Rate | 적용                                 | 적용 (Stall 3.0%로 P99.9 방어) | 2_Combo_23_Sync_Rate (All NVMe)                   |
| 자주 멈추는 느린 Disk             | Sync 필수     | 적용                                 | 미적용                       | Ref: AllExternal 상태에서<br>Stall% 58% → 31%대로 개선 가능 |

## Discussion

**내부 드라이브 2개를 사용하는 환경에서 추가 실험 필요**

**파일 포맷에 따른 추가 실험 필요**

## 향후 방향

Option 1 다른 Wal 병목 규명

Option 2 기존 실험 보완 및 결과에 대한 why 분석

감사합니다